Guia de uso da interface

Rotas Hospitalares: otimização de rotas de medicamentos e insumos com algoritmo genético e LLM (Tech Challenge Fase 2, Projeto 2)

Este guia explica, aba por aba, o que a interface web mostra e como usar cada recurso. A interface tem uma **barra lateral**, onde se escolhe a solução de rotas, uma **faixa de indicadores** no topo e **cinco abas**. As duas primeiras abas mostram o resultado da otimização. As três últimas usam uma LLM para transformar esse resultado em texto.

Aba	Para que serve	Usa LLM?
Mapa e rotas	Ver as rotas otimizadas no mapa e os números de cada veículo	Não
Comparativo	Comparar o algoritmo genético com outros métodos de roteamento	Não
Instruções	Gerar o roteiro de trabalho do motorista de um veículo	Sim
Relatórios	Gerar relatório diário, semanal e sugestões de melhoria	Sim
Pergunte às rotas	Fazer perguntas em linguagem natural sobre as entregas do dia	Sim

Antes de começar

Para abrir a interface, na pasta do projeto:

```
.venv/bin/streamlit run app/streamlit_app.py
```

A interface abre em **http://localhost:8501**. Algumas partes dependem de arquivos gerados antes pela linha de comando:

Comando	O que gera	Necessário para
rotas experiments	Melhor solução, comparativo de métodos, gráficos e resumo dos experimentos	Opção "Melhor solução dos experimentos" e aba Comparativo
rotas simulate-week	Histórico simulado de 7 dias de operação	Relatório semanal e sugestões de melhoria

Qual LLM é usada. É definida pela variável `LLM_PROVIDER` no arquivo `.env`: `gemini` (Google, na nuvem), `ollama` (modelo local, por exemplo `qwen2.5:7b`) ou `mock` (respostas fixas, sem LLM real). O rodapé da barra lateral mostra qual está ativa. Com o Ollama, o servidor precisa estar rodando (`ollama serve`) antes de abrir a interface.

Barra lateral: escolher a solução

Tudo o que as abas mostram se refere à solução escolhida aqui. Há duas opções:

Otimizar agora

Gera um cenário novo e roda o algoritmo genético na hora.

1. Ajuste o **cenário**: número de entregas (10 a 80) e a seed, que fixa o sorteio dos destinos. A mesma seed sempre gera o mesmo cenário.
2. Ajuste o **algoritmo genético**: tamanho da população, número de gerações, taxa de mutação e tipo de cruzamento (OX, PMX ou ERX).

3. Deixe marcado **Memético** para aplicar busca local (relocate e 2-opt) aos melhores indivíduos. Costuma dar rotas melhores, com um pouco mais de tempo.
4. Clique em **Otimizar**. A barra de progresso e o gráfico abaixo dela mostram o custo caindo a cada geração.

Melhor solução dos experimentos

Carrega a melhor solução salva por `rotas experiments`, sem otimizar nada. É a opção mais rápida para demonstrar o sistema.

> **Dica.** trocar de solução apaga os textos já gerados pela LLM e reinicia o chat, porque eles se referem à solução anterior.

Indicadores do topo

Logo abaixo do título aparecem seis números da solução atual:

- **Distância:** km totais percorridos por todos os veículos.
- **Custo operacional:** custo estimado em reais da operação do dia.
- **Veículos:** quantos veículos da frota foram usados.
- **Entregas:** número de entregas do cenário.
- **Até críticas (média):** tempo médio, em horas, até a chegada das entregas críticas. Quanto menor, melhor.
- **Restrições:** "atendidas" quando capacidade de carga, autonomia, janelas de horário, refrigeração e fim do turno foram respeitados; "violadas" caso contrário.

Aba 1: Mapa e rotas

Mostra onde cada veículo vai e em que ordem. Não usa LLM.

Como ler o mapa

- Cada **cor de linha** é um veículo. Os veículos podem ser ligados e desligados no controle de camadas, no canto superior direito do mapa. O nome da camada traz os km e o número de paradas.
- **Linha cheia:** trajeto real pelas ruas, obtido do serviço OSRM. **Linha tracejada:** linha reta entre as paradas, usada quando não há internet.
- A **cor do marcador** indica a prioridade: vermelho é crítica, laranja é urgente e verde é regular. Entregas críticas têm marcador maior.
- **Clique num marcador** para ver a ordem da parada, o destino, o horário previsto de chegada e os itens.

> **Atenção aos km.** O km mostrado no nome do veículo é o usado pela otimização (distância em linha reta multiplicada por 1,3). O km "pelas ruas" que aparece entre parênteses serve só para conferência.

Tabela da frota

Abaixo do mapa, uma linha por veículo: paradas, distância, carga, ocupação da capacidade, quanto da autonomia foi usado, horário de retorno ao depósito e quantas entregas são críticas e refrigeradas. Se alguma restrição foi violada, um aviso amarelo lista quais.

Convergência

Só aparece quando a solução veio de "Otimizar agora". O gráfico mostra o melhor custo a cada geração. Uma curva que estabiliza cedo indica que mais gerações não trariam ganho.

Aba 2: Comparativo

Mostra se o algoritmo genético é de fato melhor que alternativas. Todos os métodos resolvem o mesmo cenário com a mesma função de custo. Não usa LLM e depende de `rotas experiments`.

- **Tabela de métodos:** algoritmo genético, vizinho mais próximo, Clarke-Wright, OR-Tools, solução aleatória e o código base de TSP fornecido no desafio. Colunas: custo da função objetivo, km, custo em reais, se a solução é viável, tempo até as críticas, veículos usados e tempo de execução.
- **Gráficos:** comparação entre métodos, convergência e boxplot do custo entre as seeds.
- **Experimentos do AG:** as configurações testadas (população, mutação, cruzamento, memético) com a média de 5 seeds cada.

> **Dica.** para comparar métodos, olhe primeiro a coluna "viável". Uma solução mais curta que viola restrições (por exemplo, a do código base, que usa um só veículo) não é utilizável na prática.

Aba 3: Instruções

Gera o roteiro de trabalho do dia para o motorista de um veículo.

1. Escolha o **veículo** na lista. Só aparecem veículos usados na solução.
2. Clique em **Gerar instruções para o motorista** e aguarde. Com o Ollama, pode levar de alguns segundos a cerca de 1 minuto.

Não é preciso digitar nada. O sistema envia à LLM os dados da rota otimizada daquele veículo (paradas em ordem, horários, janelas, peso, itens, prioridade e refrigeração) junto com um prompt que fixa o formato da resposta:

- **Resumo da rota:** saída, retorno, km, carga, número de paradas, críticas e refrigeradas.
- **Antes de sair:** checklist de carregamento, na ordem inversa das entregas, e conferência da temperatura dos refrigerados (2 °C a 8 °C).
- **Paradas:** uma entrada por parada, com horário, itens e marcações de crítica, refrigerado e janela de horário.
- **Atenção:** riscos presentes nos dados, como janelas apertadas ou críticas no fim da rota.

Os números do texto vêm da otimização, não da LLM. O papel do modelo é redigir. O texto gerado fica guardado: trocar de veículo e voltar não gera de novo.

> **Dica.** o prompt proíbe inventar informações, mas modelos pequenos às vezes acrescentam itens genéricos (por exemplo, "verifique o tanque"). O comando `rotas llm-eval` mede isso, conferindo se os números do texto batem com os dados.

Aba 4: Relatórios

Gera textos gerenciais. Escolha o tipo e clique em **Gerar**.

Tipo	O que contém	Requer
Diário	Eficiência das rotas do dia: km, custo, ocupação dos veículos, atendimento às críticas e pontos de atenção	Só a solução atual
Semanal	Economia de km, de reais e de horas de condução na semana, comparada com o método anterior, e evolução do tempo até as críticas	rotas simulate-week
Sugestões de melhoria	Mudanças no processo propostas pela LLM a partir dos padrões da semana	rotas simulate-week

Nos tipos Semanal e Sugestões, quatro cartões no topo mostram os totais da semana antes mesmo de gerar o texto: economia de km (e em %), economia em reais, horas de condução poupadas e tempo médio até as críticas.

Aba 5: Pergunte às rotas

Um chat para perguntar sobre as rotas e entregas do dia em linguagem natural. Digite a pergunta na caixa no rodapé da página e pressione Enter. A conversa mantém o histórico, então dá para fazer perguntas de continuação.

Exemplos de perguntas

- Quem leva insulina para o Tatuapé?
- Quais entregas críticas a Van Refrigerada 2 faz?
- Que horas o veículo 1 volta ao depósito?
- Quanto economizamos em relação ao vizinho mais próximo?
- Alguma entrega está com janela de horário apertada?

Como funciona

Há dois modos, definidos pela variável `CHAT_MODE` no `.env`:

- **context** (padrão): todos os dados do dia vão junto com cada pergunta, numa única chamada à LLM. É o modo mais rápido e econômico para o volume deste projeto.
- **tools**: a LLM chama funções do sistema para buscar os fatos (buscar entrega, rota do veículo, entregas por prioridade, comparar métodos). Escala melhor para bases grandes, mas faz mais chamadas.

> **Dica.** o assistente responde só com base nos dados da solução. Se algo não estiver nos dados, ele deve responder que a informação não consta. Perguntas clínicas estão fora do escopo.

Problemas comuns

Sintoma	Causa provável e solução
Rodapé da barra lateral mostra "mock (offline)"	Nenhuma LLM real configurada. Defina LLM_PROVIDER e a chave ou o modelo no .env e reinicie.
Erro "Ollama não está respondendo"	Servidor do Ollama parado. Rode ollama serve (e ollama pull com o modelo do .env).
Erro de cota do Gemini	O plano gratuito tem limite diário por modelo. O sistema já tenta os modelos reserva. Se todos acabarem, aguarde a renovação ou troque para ollama.
Aba Comparativo ou Relatório semanal pede para rodar um comando	Faltam os arquivos de resultado. Rode rotas experiments ou rotas simulate-week.
Linhas do mapa tracejadas	Sem acesso ao serviço de ruas (OSRM). O mapa usa linhas retas; os resultados da otimização não mudam.
Texto da LLM demora	Normal com modelo local: o primeiro pedido carrega o modelo na memória.